

Laboratório de Estresse Semântico

Medindo como a complexidade literária afeta modelos de embedding

De onde veio a ideia



Bruna Martioli

Professora de Literatura — doutoranda, pesquisa sobre Agustina Bessa-Luís

Tudo começou ao assistir a um vídeo da professora de literatura Bruna Martioli, que faz doutorado sobre Agustina Bessa-Luís.

Ela comentou que tinha dificuldade em usar IA no seu trabalho: os modelos não conseguiam interpretar bem os textos literários complexos que ela analisa.

Como, eu estava estudando embeddings — virou uma pergunta de pesquisa: será que uma frase complexa e sua versão simplificada, com o mesmo significado, ficam realmente próximas quando processadas por um modelo de embedding?

Se o modelo de embedding realmente capturasse o sentido profundo, as duas versões deveriam ficar “próximas” no espaço vetorial, independente da complexidade da escrita.


O que é um embedding?

Um embedding transforma um texto em uma lista de números (um vetor) — um ponto num espaço matemático de muitas dimensões.

Textos com significado parecido caem em pontos próximos nesse espaço.

Textos com significado diferente caem em pontos distantes.

Pense num mapa: frases parecidas “moram perto” umas das outras.



Os três modelos testados

BGE-M3

BAAI

Modelo multilíngue de última geração, forte em recuperação de texto.

LaBSE

GOOGLE

Especializado em alinhamento de frases entre idiomas diferentes.

EmbeddingGemma

GOOGLE


Modelo leve, roda localmente com poucos recursos.

Por que três modelos, não um só?

Para verificar se um efeito observado é consistente entre arquiteturas diferentes — ou se é peculiaridade de um único modelo.

A ideia central: tradução intralingual

Pegamos um trecho literário complexo (metáfora, hipérbato, paradoxo...) e o reescrevemos de forma direta e simples, preservando o mesmo significado.




Pergunta central: o texto complicado e sua versão simples — que dizem a mesma coisa — ficam próximos no espaço de embedding, ou o modelo se confunde com a complexidade da forma?

Como o cosseno mede a similaridade

$$\text{sim}(A, B) = \frac{A \cdot B}{\|A\| \times \|B\|}$$

- **A e B** são os vetores (embeddings) dos dois textos sendo comparados.
- **Numerador ($A \cdot B$)** é o produto escalar entre os vetores.
- **Denominador ($\|A\| \times \|B\|$)** normaliza pelo tamanho (norma) de cada vetor.
- **Resultado** varia de -1 a 1: quanto mais perto de 1, mais “parecidos” os textos são; quanto mais perto de 0, mais diferentes.

Ângulo pequeno → maior similaridade · ângulo grande → menor similaridade



Um par do dataset: antítese em Vieira

TEXTO ORIGINAL (COMPLEXO)

“Mas ainda a [desgraça] do sementeiro do nosso Evangelho não foi a maior. A maior é a que se tem experimentado na seara aonde eu fui, e para onde venho.”

TEXTO SIMPLIFICADO

“No entanto, o sofrimento dos pregadores do Evangelho em geral não foi o pior. O pior sofrimento é aquele que os missionários vivenciaram na região do Maranhão, de onde eu voltei recentemente e para onde pretendo ir novamente.”

Ambos dizem essencialmente a mesma coisa, mas o original usa a antítese retórica de Vieira (“não foi a maior... a maior é...”), enquanto a versão simplificada reescreve isso de forma direta. Esse é um dos pares com maior divergência entre os três modelos testados na análise exploratória.

BGE-M3 $\approx 0,71$

LaBSE $\approx 0,74$

EmbeddingGemma $\approx 0,60$

Padrão consistente com o piloto: figuras que dependem de oposição lógica — como a antítese — tendem a “derivar” mais no espaço de embedding do que reconstruções puramente sintáticas.

Dois extremos encontrados no piloto

MENOR SIMILARIDADE

Padre Antônio Vieira — Paradoxo

“É uma arte sem arte, caia onde cair”

→ “A pregação não deve seguir regras rígidas; deve ser simples e natural”

similaridade de cosseno $\approx 0,34 - 0,51$

MAIOR SIMILARIDADE

Machado de Assis — Zeugma (Quincas Borba)

“Nos pés, chinelas de damasco; na cabeça, um gorro de seda; na boca, um riso azul claro”

→ “Ele usava chinelos de damasco, um chapéu de seda, e mostrava um sorriso suave”

similaridade de cosseno $\approx 0,87 - 0,88$

Mesmo tamanho de escala (0 a 1): o paradoxo “deriva” muito mais no espaço de embedding do que o zeugma.

O que isso sugere

MAIS DERIVA

Paradoxo, Antítese

Figuras que exigem raciocínio lógico ou contradição aparente tendem a afastar mais o texto original de sua versão simples no espaço de embedding.

MENOS DERIVA

Zeugma, Elipse

Figuras que são reconstrução sintática mais mecânica preservam melhor a proximidade entre original e versão simples.

Leitura preliminar, baseada em n=1 por fenômeno: como os próximos slides mostram, essa hierarquia por categoria retórica não se sustentou com mais dados — o que de fato explica a queda é o contexto ausente e o tamanho da reescrita, não a figura em si.

Fenômeno retórico ou contexto perdido?

PRECISA DE CONTEXTO PRÉVIO

6 de 12 pares do piloto

Ex.: “Mas ainda...” (Vieira), apóstrofe a “tu, feto esquecido” (Anjos), elisão “(...)” (Andrade)

→ conectivo, dêixis ou apóstrofe sem antecedente dentro do trecho

similaridade média $\approx 0,57$

AUTOCONTIDO

6 de 12 pares do piloto

Ex.: Rubião (Assis), Miranda (Azevedo), Macunaíma (Andrade)

→ personagem e cena descritos dentro da própria frase

similaridade média $\approx 0,73$

5 dos 6 pares “Lógico-pragmática” (Seção 6) também precisam de contexto prévio, contra 1 dos 5 “Lexical/Retórica” — os dois fatores estão praticamente confundidos neste piloto (Mann-Whitney $p \approx 0,004$). Ainda não dá para saber se é o fenômeno ou o contexto perdido que reduz a similaridade.

A hierarquia “Paradoxo pior” não se sustentou

PARADOXO — SÓ n=1 (PILOTO)

vieira_002, o único par do piloto

Ex.: “É uma arte sem arte, caia onde cair” (Vieira)

→ parecia o fenômeno mais hostil aos embeddings do dataset

similaridade $\approx 0,39$ (mínimo do piloto)

PARADOXO — AGORA n=4

+ Camões e 2 sonetos de Gregório de Matos

Ex.: matos_001 chega a 0,89 — o maior valor do dataset inteiro

→ virou o fenômeno de MAIOR desvio padrão, não o de menor média

similaridade média $\approx 0,79$ (DP 0,19–0,28)

O extremo “Paradoxo é o pior fenômeno” não se sustentou: era uma leitura de vieira_002 especificamente (também dependente de contexto — slide anterior), não do fenômeno em si. O confound de contexto segue significativo com n=25 (Mann-Whitney $p \approx 0,016$).

Não é o fenômeno — são duas variáveis reais

FATOR 1 — TAMANHO

Razão de expansão do texto

Quanto mais a versão simplificada precisa se alongar, proporcionalmente, para compensar a figura retórica removida

→ correlação negativa moderada, nos três modelos, entre razão de tamanho e similaridade

$r \approx -0,43$ a $-0,47$ • $p < 0,05$ (3 modelos)

FATOR 2 — CONTEXTO

Dependência de contexto ausente

Controlando estatisticamente pela razão de tamanho, numa regressão múltipla com os dois fatores juntos

→ continua reduzindo a similaridade mesmo controlando pelo tamanho

$p \approx 0,007$ a $0,035$ • R^2 0,35–0,42

Numa regressão múltipla com os dois fatores juntos, ambos seguem estatisticamente significativos controlando um pelo outro — evidência de que são majoritariamente independentes, não um mascarando o outro. Com $n=25$ e 2 preditores (22 graus de liberdade residuais), é indicativo, não conclusivo.

O que isso sugere para IA sobre documentos (RAG)

COMO FUNCIONA UM RAG

Busca por embedding decide o que o LLM lê

Ferramentas que respondem sobre documentos longos (PDFs, livros) geralmente não mandam o texto inteiro ao modelo — quebram em pedaços (chunks) e recuperam só os mais similares à pergunta, por embedding

→ um corte malfeito decide, antes do LLM entrar em ação, que ele nunca vai ver o trecho certo

a etapa de busca já erra antes do LLM começar

ACHADO DESTE PROJETO

Trecho cortado sem contexto = embedding degradado

Um conectivo pressuposicional (“mas ainda...”), uma referência não resolvida, uma citação sem o entorno — não é a complexidade do texto que derruba a similaridade, é o corte

→ o mesmo mecanismo medido aqui em literatura pode atuar em qualquer fronteira de chunk

não é uma falha do LLM — é uma falha do recorte

Isso ainda não foi testado em texto não-literário nem contra diferentes estratégias de corte de chunk — é uma pergunta de continuidade registrada no projeto, não uma conclusão fechada. Mas é testável: comparar a resposta da IA sobre um trecho colado com e sem o contexto ao redor.

Próximos passos

01

Expandir o dataset (concluído)

Dataset ampliado de 12 para 25 pares — mais Camões, Gregório de Matos, Machado de Assis e Fernando Pessoa/Ricardo Reis (Seção 8 do notebook).

02

Testar correlação com o tamanho do texto (concluído)

A diferença absoluta de caracteres não correlaciona com a similaridade, mas a razão de expansão (simplificado / original) sim: $r \approx -0,43$ a $-0,47$, $p < 0,05$ nos três modelos (Seção 8.1).

03

Regressão múltipla: dois fatores independentes (concluído)

Controlando dependência de contexto e razão de tamanho um pelo outro, os dois seguem significativos (R^2 0,35–0,42) — evidência de que são majoritariamente independentes, não uma hierarquia de fenômenos retóricos. Com $n=25$ e 2 preditores (22 gl residuais), falta um dataset maior e balanceado (categoria $\times$ contexto $\times$ tamanho) para separar os efeitos com mais poder estatístico.