

# Laboratório de Estresse Semântico

Medindo como a complexidade literária afeta modelos de embedding

## De onde veio a ideia



**Bruna Martioli**

Professora de Literatura — doutoranda, pesquisa sobre Agustina Bessa-Luís

Tudo começou ao assistir a um vídeo da professora de literatura Bruna Martioli, que faz doutorado sobre Agustina Bessa-Luís.

Ela comentou que tinha dificuldade em usar IA no seu trabalho: os modelos não conseguiam interpretar bem os textos literários complexos que ela analisa.

Como, eu estava estudando embeddings — virou uma pergunta de pesquisa: será que uma frase complexa e sua versão simplificada, com o mesmo significado, ficam realmente próximas quando processadas por um modelo de embedding?

*Se o modelo de embedding realmente capturasse o sentido profundo, as duas versões deveriam ficar “próximas” no espaço vetorial, independente da complexidade da escrita.*


# O que é um embedding?

Um embedding transforma um texto em uma lista de números (um vetor) — um ponto num espaço matemático de muitas dimensões.

Textos com significado parecido caem em pontos próximos nesse espaço.

Textos com significado diferente caem em pontos distantes.

*Pense num mapa: frases parecidas “moram perto” umas das outras.*



## Os três modelos testados

### BGE-M3

BAAI

Modelo multilíngue de última geração, forte em recuperação de texto.

### LaBSE

GOOGLE

Especializado em alinhamento de frases entre idiomas diferentes.

### EmbeddingGemma

GOOGLE


Modelo leve, roda localmente com poucos recursos.

#### Por que três modelos, não um só?

Para verificar se um efeito observado é consistente entre arquiteturas diferentes — ou se é peculiaridade de um único modelo.

# A ideia central: tradução intralingual

Pegamos um trecho literário complexo (metáfora, hipérbato, paradoxo...) e o reescrevemos de forma direta e simples, preservando o mesmo significado.




*Pergunta central: o texto complicado e sua versão simples — que dizem a mesma coisa — ficam próximos no espaço de embedding, ou o modelo se confunde com a complexidade da forma?*

## Como o cosseno mede a similaridade

$$\text{sim}(A, B) = \frac{A \cdot B}{\|A\| \times \|B\|}$$

- **A e B** são os vetores (embeddings) dos dois textos sendo comparados.
- **Numerador ( $A \cdot B$ )** é o produto escalar entre os vetores.
- **Denominador ( $\|A\| \times \|B\|$ )** normaliza pelo tamanho (norma) de cada vetor.
- **Resultado** varia de -1 a 1: quanto mais perto de 1, mais “parecidos” os textos são; quanto mais perto de 0, mais diferentes.

Ângulo pequeno → maior similaridade · ângulo grande → menor similaridade



## Um par do dataset: antítese em Vieira

### TEXTO ORIGINAL (COMPLEXO)

*“Mas ainda a [desgraça] do sementeiro do nosso Evangelho não foi a maior. A maior é a que se tem experimentado na seara aonde eu fui, e para onde venho.”*

### TEXTO SIMPLIFICADO

*“No entanto, o sofrimento dos pregadores do Evangelho em geral não foi o pior. O pior sofrimento é aquele que os missionários vivenciaram na região do Maranhão, de onde eu voltei recentemente e para onde pretendo ir novamente.”*

Ambos dizem essencialmente a mesma coisa, mas o original usa a antítese retórica de Vieira (“não foi a maior... a maior é...”), enquanto a versão simplificada reescreve isso de forma direta. Esse é um dos pares com maior divergência entre os três modelos testados na análise exploratória.

**BGE-M3**  $\approx 0,71$

**LaBSE**  $\approx 0,74$

**EmbeddingGemma**  $\approx 0,60$

*Padrão consistente com o piloto: figuras que dependem de oposição lógica — como a antítese — tendem a “derivar” mais no espaço de embedding do que reconstruções puramente sintáticas.*

## Dois extremos encontrados no piloto

### MENOR SIMILARIDADE

#### Padre Antônio Vieira — Paradoxo

*“É uma arte sem arte, caia onde cair”*

→ “A pregação não deve seguir regras rígidas; deve ser simples e natural”

similaridade de cosseno  $\approx 0,34 - 0,51$

### MAIOR SIMILARIDADE

#### Machado de Assis — Zeugma (Quincas Borba)

*“Nos pés, chinelas de damasco; na cabeça, um gorro de seda; na boca, um riso azul claro”*

→ “Ele usava chinelos de damasco, um chapéu de seda, e mostrava um sorriso suave”

similaridade de cosseno  $\approx 0,87 - 0,88$

Mesmo tamanho de escala (0 a 1): o paradoxo “deriva” muito mais no espaço de embedding do que o zeugma.



## O que isso sugere

### MAIS DERIVA

#### *Paradoxo, Antítese*

Figuras que exigem raciocínio lógico ou contradição aparente tendem a afastar mais o texto original de sua versão simples no espaço de embedding.

### MENOS DERIVA

#### *Zeugma, Elipse*

Figuras que são reconstrução sintática mais mecânica preservam melhor a proximidade entre original e versão simples.

**Achado preliminar: os modelos de embedding parecem depender mais da forma da frase do que seria ideal.**

# Fenômeno retórico ou contexto perdido?

## PRECISA DE CONTEXTO PRÉVIO

### 6 de 12 pares do piloto

Ex.: “Mas ainda...” (Vieira), apóstrofe a “tu, feto esquecido” (Anjos), elisão “(...)” (Andrade)

→ conectivo, dêixis ou apóstrofe sem antecedente dentro do trecho

similaridade média  $\approx 0,57$

## AUTOCONTIDO

### 6 de 12 pares do piloto

Ex.: Rubião (Assis), Miranda (Azevedo), Macunaíma (Andrade)

→ personagem e cena descritos dentro da própria frase

similaridade média  $\approx 0,73$

5 dos 6 pares “Lógico-pragmática” (Seção 6) também precisam de contexto prévio, contra 1 dos 5 “Lexical/Retórica” — os dois fatores estão praticamente confundidos neste piloto (Mann-Whitney  $p \approx 0,004$ ). Ainda não dá para saber se é o fenômeno ou o contexto perdido que reduz a similaridade.

# A hierarquia “Paradoxo pior” não se sustentou

## PARADOXO — SÓ n=1 (PILOTO)

vieira\_002, o único par do piloto

Ex.: “É uma arte sem arte, caia onde cair” (Vieira)

→ parecia o fenômeno mais hostil aos embeddings do dataset

similaridade  $\approx 0,39$  (mínimo do piloto)

## PARADOXO — AGORA n=4

+ Camões e 2 sonetos de Gregório de Matos

Ex.: matos\_001 chega a 0,89 — o maior valor do dataset inteiro

→ virou o fenômeno de MAIOR desvio padrão, não o de menor média

similaridade média  $\approx 0,79$  (DP 0,19–0,28)

O extremo “Paradoxo é o pior fenômeno” não se sustentou: era uma leitura de vieira\_002 especificamente (também dependente de contexto — slide anterior), não do fenômeno em si. O confound de contexto segue significativo com n=25 (Mann-Whitney  $p \approx 0,016$ ).

# Próximos passos

01

## Expandir o dataset (concluído)

Dataset ampliado de 12 para 25 pares — mais Camões, Gregório de Matos, Machado de Assis e Fernando Pessoa/Ricardo Reis (Seção 8 do notebook).

02

## Testar correlação com o tamanho do texto

Verificar se a extensão do fragmento, por si só, explica parte da deriva observada.

03

## Análise estatística mais robusta

Com  $n=25$ , Paradoxo, Antítese, Hipérbato e Zeugma já têm múltiplas observações (Seção 8) — e a hierarquia original não se sustentou. Falta balancear autocontido/dependente de contexto dentro de cada fenômeno para separar os dois efeitos.